Eléments de méthodologie

Julien VELCIN

https://velcin.github.io

ECL-3A
Master Informatique
ECL - LIRIS - CNRS

Plan

Préambule
- Méthode scientifique
- Panorama des méthodes

Méthodologie
- Préparation
- Exploration
- Classification automatique
- Recherche d'information

Plan

Préambule
- Méthode scientifique
- Panorama des méthodes

Méthodologie
- Préparation
- Exploration
- Classification automatique
- Recherche d'information

Méthode scientifique

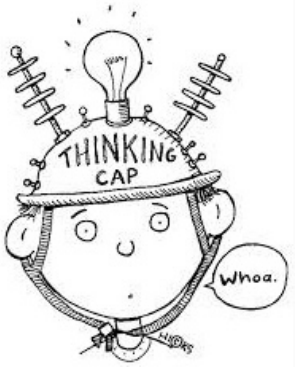

- Objectif : produire de nouvelles connaissances scientifiques
- Moyens pour y parvenir : observation, modélisation, mesures, rigueur, reproductibilité
- En réalité, une très grande variété d'approches, techniques, méthodes de validation, etc.

https://quizlet.com/ca/531061447/scientific-method-flash-cards/

Méthode scientifique

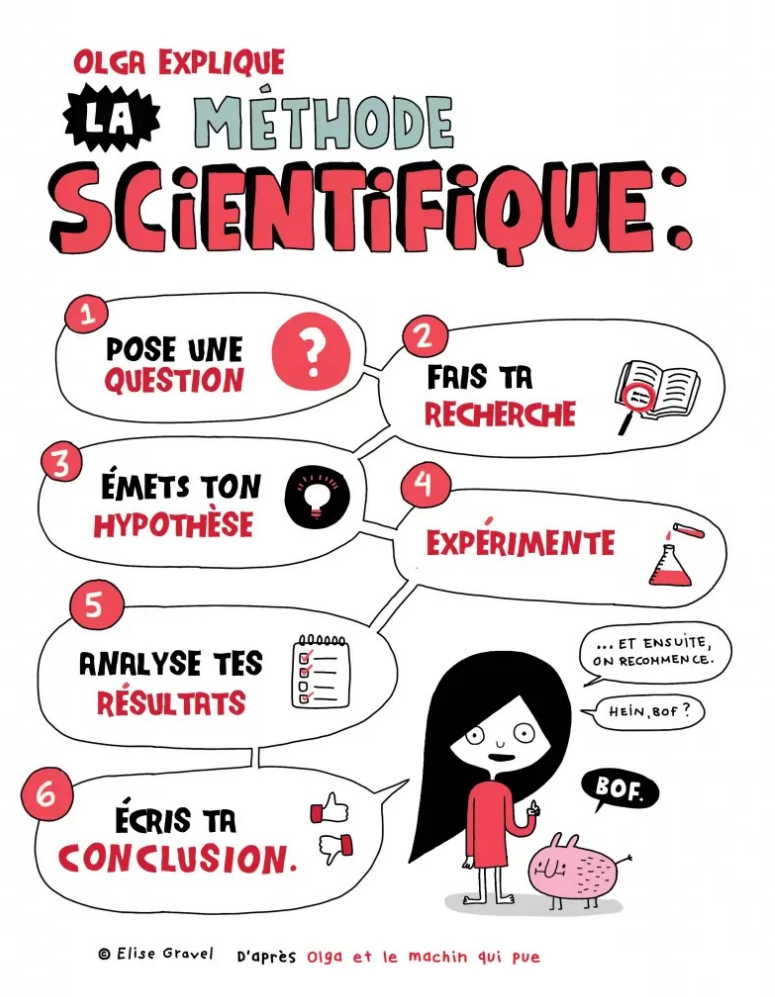

Illustration par Elise Gravel (`https://elisegravel.com`)

Plan

Préambule
- Méthode scientifique
- Panorama des méthodes

Méthodologie
- Préparation
- Exploration
- Classification automatique
- Recherche d'information

Quelles méthodes pour quels objectifs ?

Mieux comprendre les données

Utilisation de statistiques simples, visualisation des données, algorithmes de regroupement non supervisé (*clustering*)

Quelles méthodes pour quels objectifs ?

Mieux comprendre les données

Utilisation de statistiques simples, visualisation des données, algorithmes de regroupement non supervisé (*clustering*)

Détecter des erreurs, travailler sur la qualité

Algorithmes de détection de données aberrantes (*outliers*), retirer les données redondantes (doublons), compléter les données manquantes...

Quelles méthodes pour quels objectifs ?

Mieux comprendre les données

Utilisation de statistiques simples, visualisation des données, algorithmes de regroupement non supervisé (*clustering*)

Détecter des erreurs, travailler sur la qualité

Algorithmes de détection de données aberrantes (*outliers*), retirer les données redondantes (doublons), compléter les données manquantes...

Trouver des règles générales

Test d'hypothèses à partir d'échantillons (cf. statistiques inférentielles), extraction de règles d'association, prédiction à l'aide d'algorithme d'apprentissage automatique

Quelles méthodes pour quels objectifs ?

Mieux comprendre les données

Utilisation de statistiques simples, visualisation des données, algorithmes de regroupement non supervisé (*clustering*)

Détecter des erreurs, travailler sur la qualité

Algorithmes de détection de données aberrantes (*outliers*), retirer les données redondantes (doublons), compléter les données manquantes...

Trouver des règles générales

Test d'hypothèses à partir d'échantillons (cf. statistiques inférentielles), extraction de règles d'association, prédiction à l'aide d'algorithme d'apprentissage automatique

Réaliser des prévisions

Les techniques varient en fonction de la nature des données : algorithmes basés sur des modèles de séries temporelles, scoring / régression pour les valeurs continues, classification...

Panorama des méthodes

Préparation des données

- Identifier les données pertinentes (entités ? relations ?)
- Rassembler les données (fusion, jointure...)
- Identifier les caractéristiques pertinentes
- Traiter les valeurs erronées, manquantes...

Exploration

- Calcul de statistiques simples (univariées, bivariées)
- Techniques de visualisation
- Découvertes de motifs
- Algorithmes de clustering

Prédiction / prévision

- Algorithmes de régression et de classification (arbres de décision, SVM, réseaux de neurones...)

Plan

Préambule
- Méthode scientifique
- Panorama des méthodes

Méthodologie
- Préparation
- Exploration
- Classification automatique
- Recherche d'information

Plan

Préambule
- Méthode scientifique
- Panorama des méthodes

Méthodologie
- Préparation
- Exploration
- Classification automatique
- Recherche d'information

Assembler les données

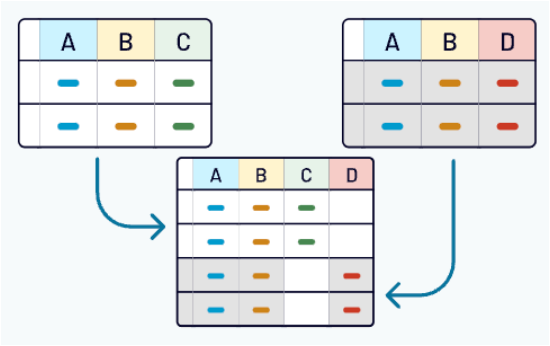

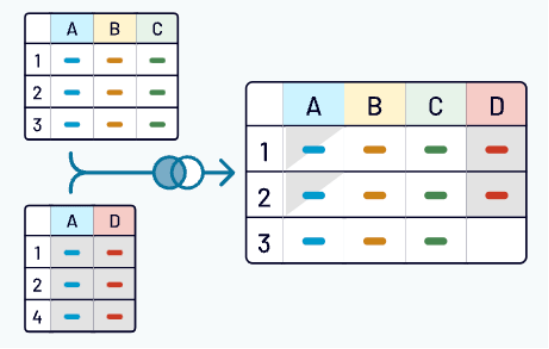

- Les données sont réparties (plusieurs fichiers, DBs...).
- Il faut souvent (au moins) quelques milliers d'instances pertinentes.
- Il faut faire attention à la représentativité des données.
- C'est une phase qui peut être longue, difficile mais importante.

Quelles caractéristiques choisir ?

- C'est souvent à vous d'identifier voire de construire les bonnes variables.
- **Identifier** les variables pertinentes peut bénéficier des connaissances expertes et de la phase d'exploration des données (cf. ce qui suit).
- On filtre souvent les variables qui ne permettent pas de généraliser (ex. des identifiants uniques), qui seront difficiles à produire en conditions réelles, qui sont trop bruitées ou trop corrélées entre elles.
- On peut **construire** ses propres caractéristiques suivant la nature du problème, mais attention à l'explosion du nombre de variables !

Traiter les données erronées

- La présence d'une valeur négative alors que tout doit être positif
  - Parfois, -1 veut dire "absent" (!) => valeurs manquantes
  - Elle peut venir d'erreur de frappe/saisi
- Les **outliers** dans des données numériques (souvent détectables)
- Les redondances et données dupliquées
  - La répétition peut influencer les résultats.
  - Est-ce que l'information est plus importante car 2 fois présente ?

Données manquantes

Les raisons en sont variées :

- simple oubli,
- erreurs de frappe,
- changement de méthode de relevée,
- impossibilité de mesure, etc.

Données manquantes

Les raisons en sont variées :

- simple oubli,
- erreurs de frappe,
- changement de méthode de relevée,
- impossibilité de mesure, etc.

Trouver la valeur manquante s'appelle l'**imputation** et peut se faire de différentes façons :

- modalité traitée à part,
- utilisation d'une valeur moyenne (variable continue) / fréquentes (variable catégorielle),
- prédiction à partir des autres variables à l'aide d'un algorithme d'apprentissage automatique.

Données hétérogènes

- La plupart des modèles requièrent un **format homogène** des données, par ex. des variables uniquement numériques.
- Intégrer des variables catégorielles : le codage disjonctif complet, ou OHE (*One Hot Encoding*)

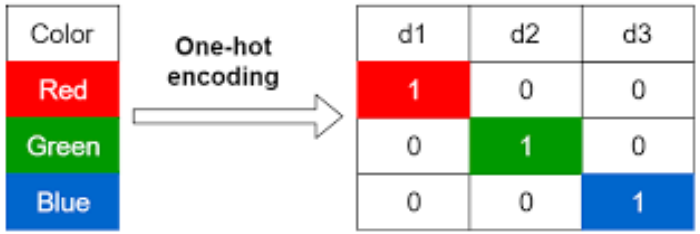

- On peut discrétiser les variables continues de différentes manières :

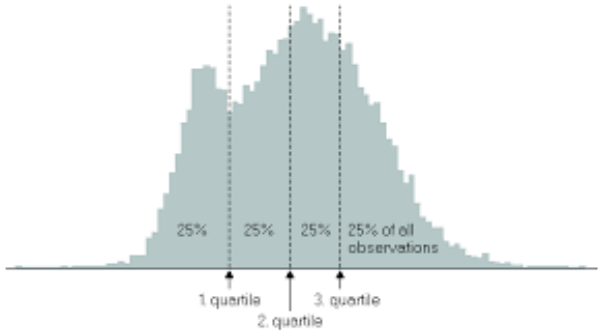

- Plus généralement, la conversion des différentes variables dépend de la nature des données (ex. des données textuelles)

Normalisation des valeurs

- Les algorithmes d'analyse sont souvent sensibles au domaine de variation des variables.
- On cherche à rendre les valeurs comparables d'une variable à l'autre pour éviter qu'une variable prenne un poids trop important.

Normalisation des valeurs

- Les algorithmes d'analyse sont souvent sensibles au domaine de variation des variables.
- On cherche à rendre les valeurs comparables d'une variable à l'autre pour éviter qu'une variable prenne un poids trop important.
- Différentes techniques usuelles :
  - Normalisation simple si $x_i \in X$:

$$\frac{x_i - \min(X)}{\max(X) - \min(X)}$$

  - Valeurs centrées-réduites :

$$\frac{x_i - \mu}{\sigma}$$

    où μ désigne la moyenne de X et σ sont écart type.
    On obtient ainsi des valeurs centrées en 0 d'écart type 1.

Plan

Préambule
- Méthode scientifique
- Panorama des méthodes

Méthodologie
- Préparation
- Exploration
- Classification automatique
- Recherche d'information

Statistiques simples

La première étape revient souvent à réaliser une analyse descriptive simple à base de statistiques comme :

- Comptage : nombre d'exemples (ou instances) à notre disposition, nombre de caractéristiques / variables qui permettent de les décrire
- Statistiques univariées
  - variables numériques : moyenne, médiane, écart type, IQR...
  - variables catégorielles : mode (valeur la plus fréquente), distribution...
- Statistiques bivariées
- Corrélation entre les variables

Visualisation

Statistiques simples

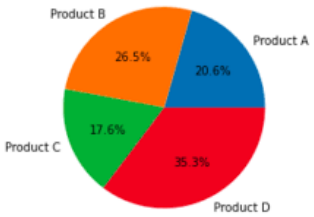

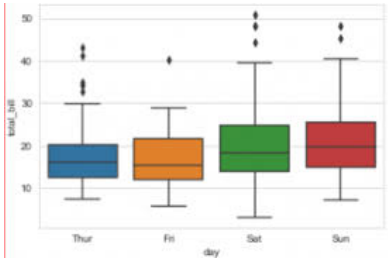

Statistiques bivariées

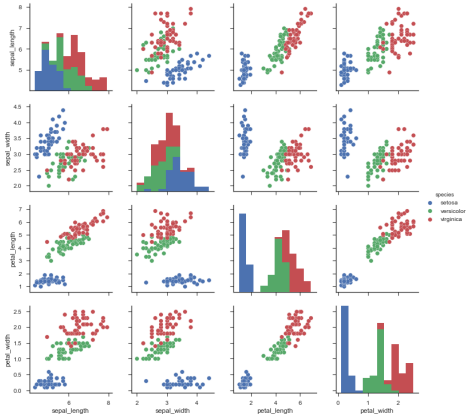

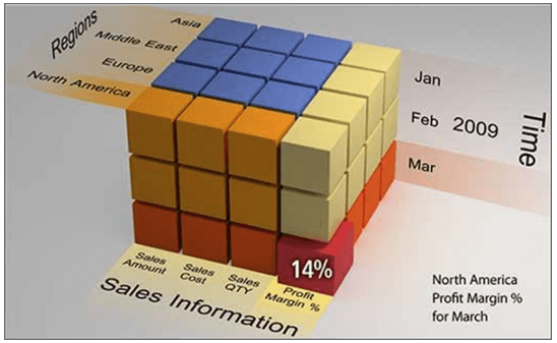

Multidimensionnel

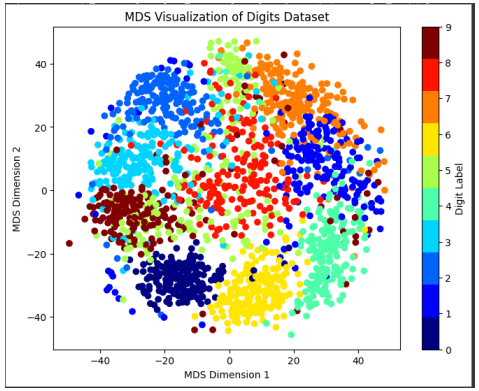

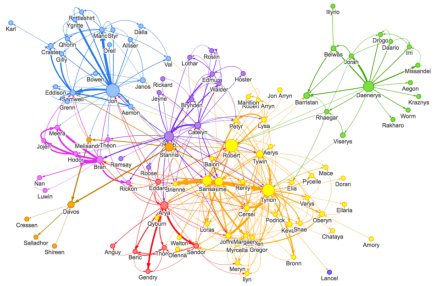

Clustering

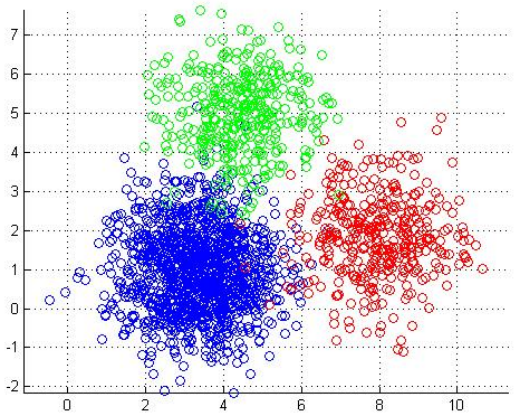

K-Means

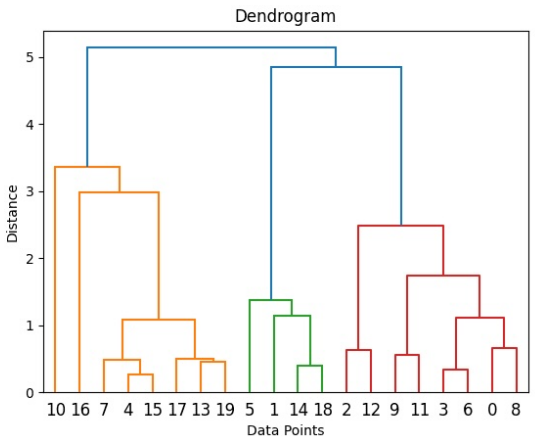

CHA

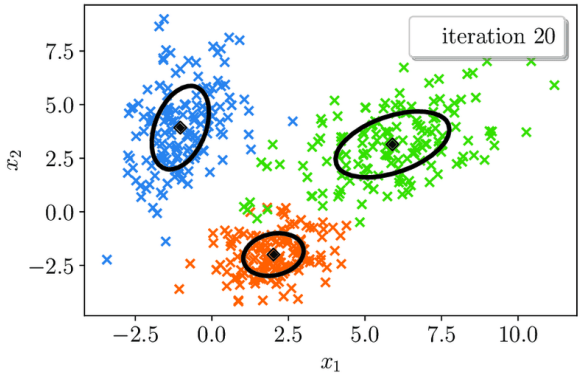

Modèle de mélange

DBScan

Plan

Préambule
- Méthode scientifique
- Panorama des méthodes

Méthodologie
- Préparation
- Exploration
- Classification automatique
- Recherche d'information

Positionnement vis-à-vis de l'IA

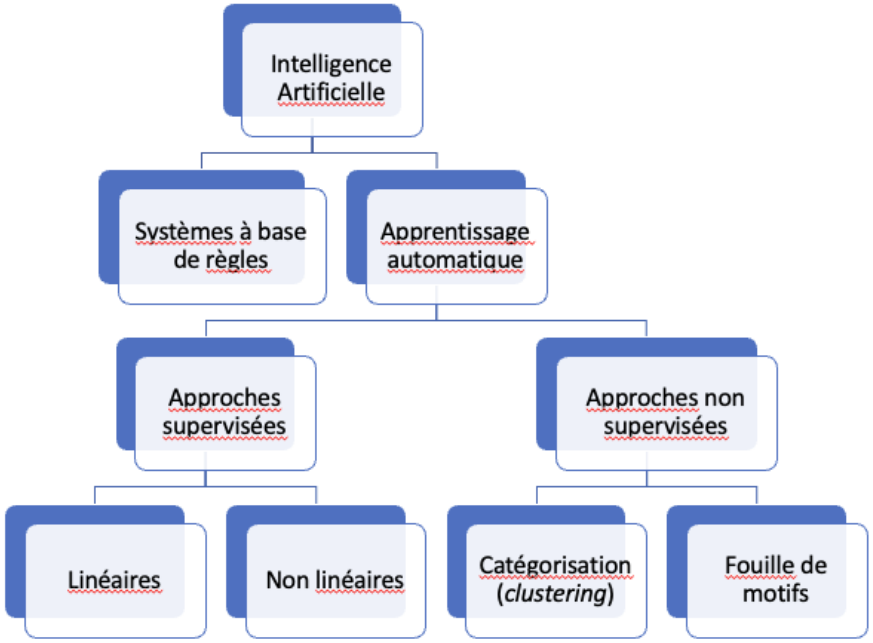

Quelques notations

- les individus (observations) sont décrits par un ensemble de p variables aléatoires explicatives $\mathbf{X} = (X_1, \ldots, X_p) \in E$ ($E = \mathbb{R}^p, \ldots$)
- $\mathbf{X}_i = (X_{i1}, \ldots, X_{ip})$ sont les variables explicatives pour l'individu i ($1 \leq i \leq n$)
- $Z_i \in \{1, \ldots, K\}$ est le numéro de la classe de l'individu i

Classer automatiquement

Objectif de la tâche

- Attribuer à chaque objet / exemple / instance de X une classe de Z.
- Le nombre de classes et le lien entre les $x \in X$ et les classes $z \in Z$ peuvent être plus ou moins connus, via l'intervention d'un **professeur** ou **oracle**.

Moyens pour y parvenir

- utilisation de **règles** qui attribuent une classe à un objet (ex. des systèmes experts)
- **apprentissage automatique** (*machine learning*) d'un modèle qui peut être utilisé pour classer les objets (par ex. via de l'apprentissage supervisé et/ou par renforcement)

Classification non supervisée *vs* supervisée

Classification supervisée

- Z_i connue (signification connue a priori)
- objectif : à partir de l'observation de $(\mathbf{X}_1, Z_1), \ldots, (\mathbf{X}_n, Z_n)$ construire une règle de classement (**classifieur**) r :

$$r : \mathbf{X} \longrightarrow r(X) = Z$$

- Utiliser cette règle de classement pour classer de nouveaux individus de classes inconnues (on parle d'**inférence**).

Classification non supervisée

- Z_i inconnue (aucun à priori)
- objectif : à partir de l'observation de $\mathbf{X}_1, \ldots, \mathbf{X}_n$, trouver $Z_1, \ldots, Z_n$ *sans indication* spécifiquement donnée par un oracle
- Les classes sont ensuite interprétées.

Apprentissage automatique inductif

Aristote

“La connaissance vient du monde”

Apprentissage automatique inductif

Aristote

“La connaissance vient du monde”

Définition

Trouver des règles générales (voire des concepts) à partir d’un ensemble d’observations particulières

Apprentissage automatique inductif

Aristote

“La connaissance vient du monde”

Définition

Trouver des règles générales (voire des concepts) à partir d’un ensemble d’observations particulières

Différents types d’apprentissage

- apprentissage par cœur
- apprentissage à partir de cas
- apprentissage à partir d’exemples
- apprentissage par renforcement
- apprentissage par abduction

Applications

Classification non supervisée

- analyse exploratoire : donner une représentation simplifiée des données pour mieux les comprendre
- exemple : typologie clients en marketing (Gestion de la relation clients / CRM - Customer Relationship Management)

Classification supervisée

- analyse prédictive : prédire une variable (Z) qualitative à partir de variables explicatives ($\mathbf{X}$)
- exemples : prédire si un prospect va acheter le produit qu'on lui propose, prédire la probabilité qu'un patient soit atteint d'une certaine maladie...

Exemple de classification pour la reconnaissance d'objets dans des images

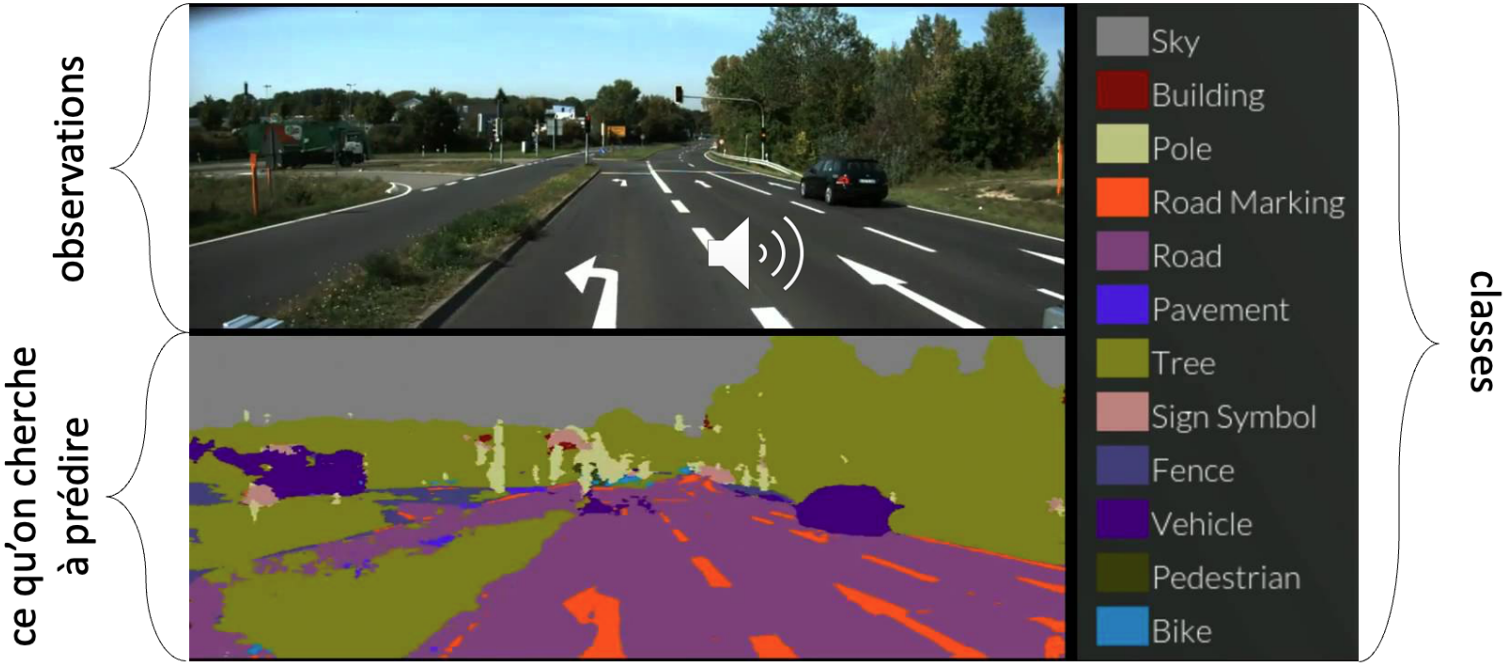

Exemple de classification pour la pris de décision

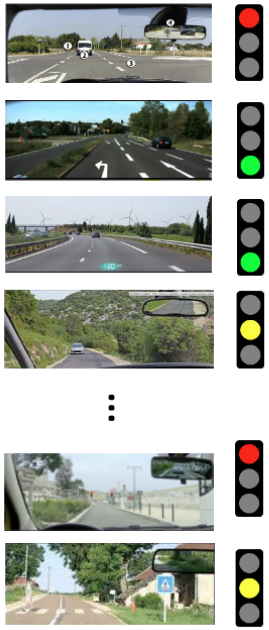

principe inductif

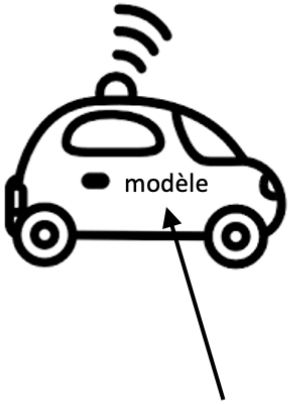

nouvelle situation

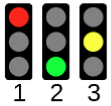

?

attention : il s'agit d'un modèle *mathématique !*

Apprentissage linéaire vs. non linéaire

Les problèmes peuvent être assez faciles (cas linéaire) ou plus difficiles (cas non linéaire). Voilà une illustration pour la tâche de classification :

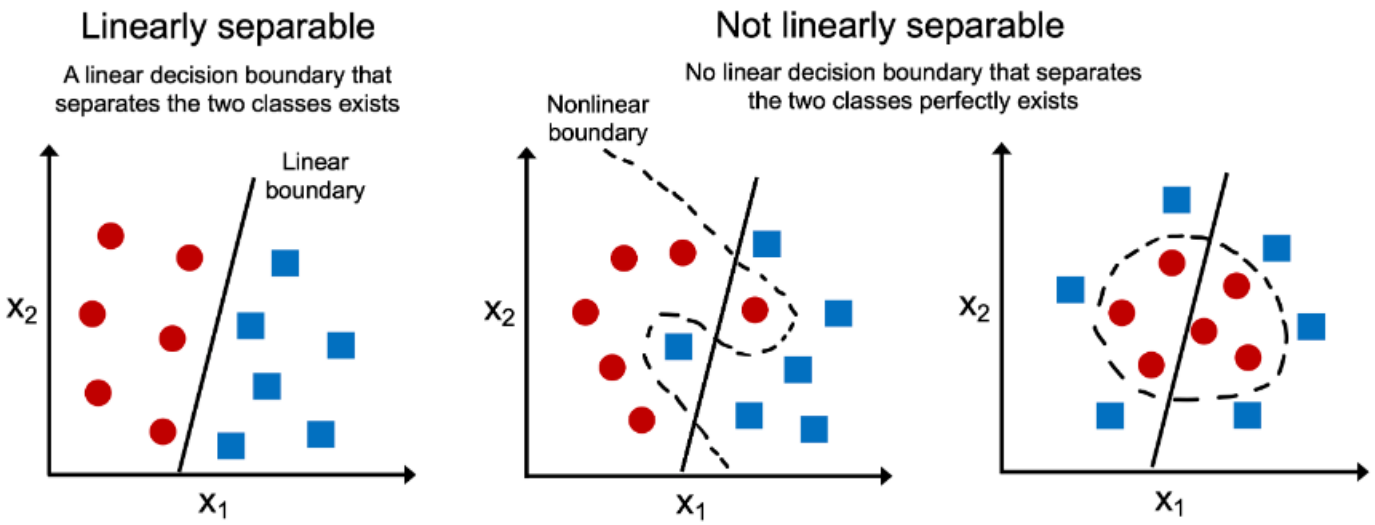

Apprentissage linéaire vs. non linéaire

Les problèmes peuvent être assez faciles (cas linéaire) ou plus difficiles (cas non linéaire). Voilà une illustration pour la tâche de classification :

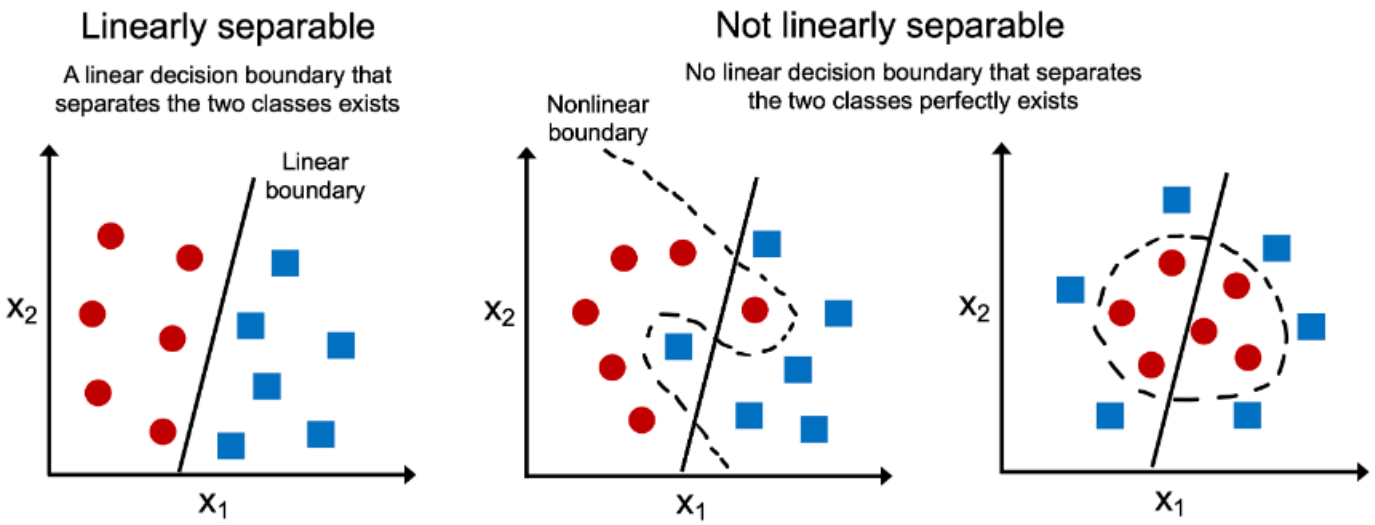

Lorsque le cas est non linéaire, plusieurs stratégies peuvent être mises en œuvre comme :

- développer un modèle **plus complexes** (plus de paramètres) pour mieux correspondre aux données,
- **projeter** les données dans un nouvel espace dans lequel le problème devient linéaire.

Apprentissage de représentations

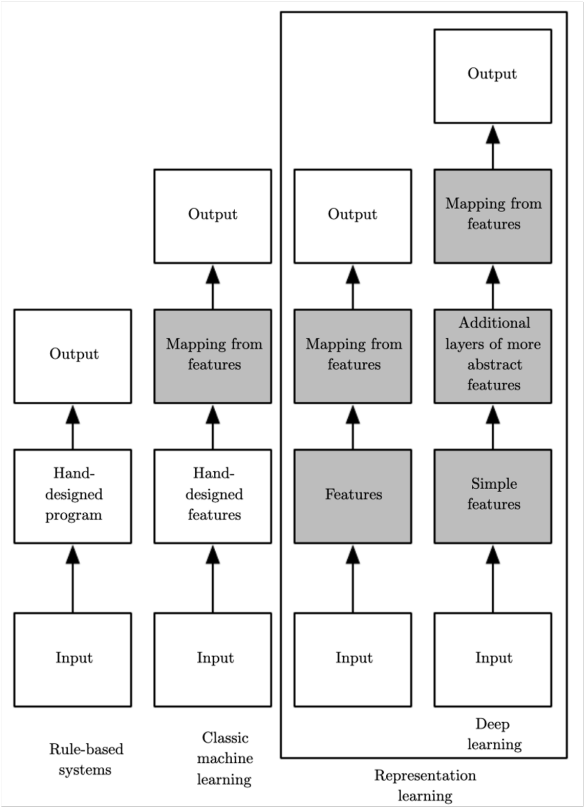

	matricul	departem	ptvente	sexe	age	sitfamil	anciente	csp	codeqlt
9	941007	31	1	Shom	45	Fmar	393	Pouv	A
10	981681	31	1	Shom	38	Fcel	63	Pcad	D
11	1231602	31	1	Shom	60	Fmar	321	Pcad	A
12	1248922	65	2	Shom	34	Fcel	362	Pemp	B
13	1252395	31	2	Shom	56	Fmar	187	Pcad	A
14	1343806	31	1	Shom	49	Fmar	209	Pcad	A
15	1544241	65	1	Sfem	61	Fsep	185	Psan	A
16	1740892	31	4	Sfem	41	Fdiv	268	Psan	A
17	1970765	31	1	Shom	50	Fmar	94	Pcad	A
18	2647067	24	1	Shom	43	Fcel	85	Part	B
19	2849823	31	1	Shom	26	Fcel	75	Psan	B
20	3258308	31	1	Shom	52	Fmar	38	Pcad	B
21	3346139	31	1	Shom	32	Fcel	147	Pcad	A
22	3901483	32	2	Shom	33	Fcel	162	Pcad	D
23	5023873	82	5	Sfem	43	Fmar	18	Pemp	C

Deep Learning, by I. Goodfellow, Y. Bengio and A. Courville, MIT Press, 2016:
http://www.deeplearningbook.org

Biais d'apprentissage

- Choix réalisés afin de réduire l'espace des solutions possibles (espace des **hypothèses**)
- En apprentissage de concept : moyen de préférer une généralisation à une autre
- Guident le processus d'apprentissage
- Absolue nécessité des biais dans le processus d'apprentissage (T. Mitchell, 1980)
- Exemple de biais :
  - biais de simplicité (ou Rasoir d'Occam),
  - biais inductif
  - biais de restriction
  - etc.

Sous-apprentissage et sur-apprentissage

Exemple avec un problème de régression :

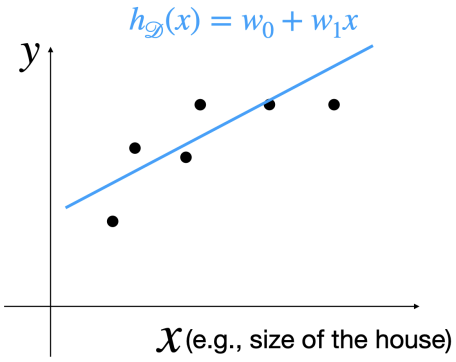

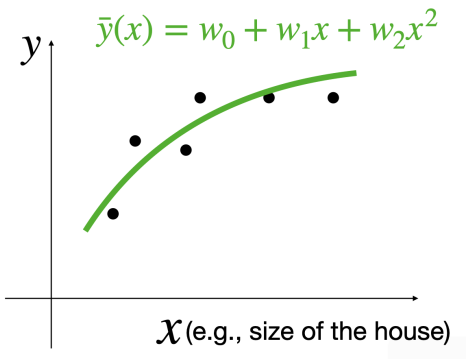

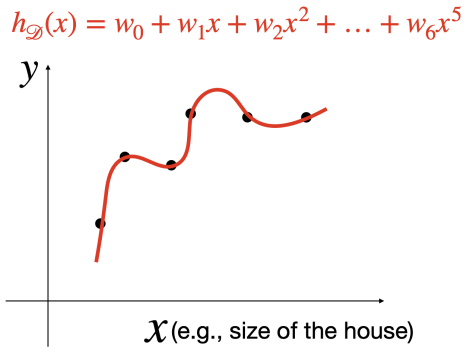

Sous-apprentissage et sur-apprentissage

Exemple avec un problème de régression :

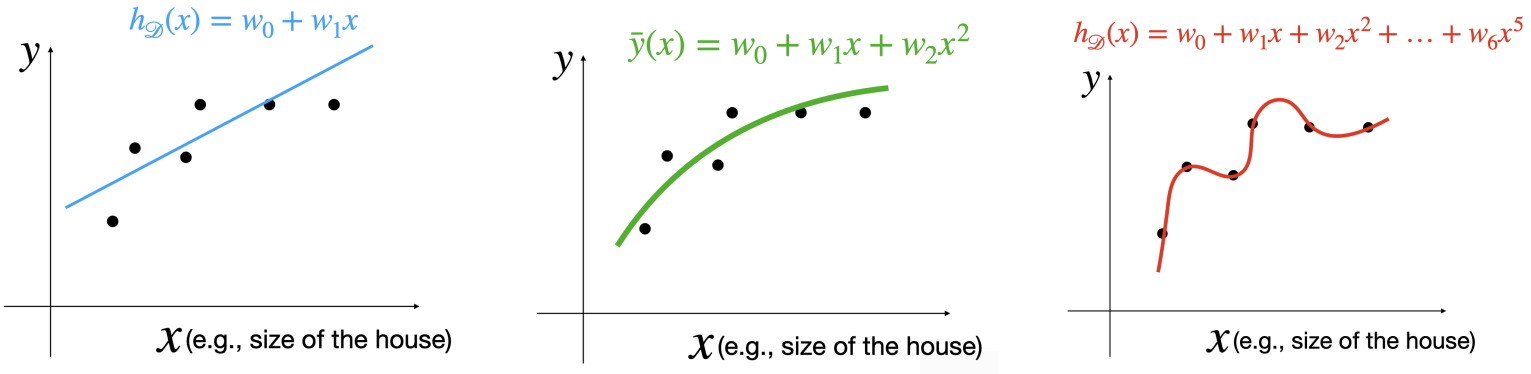

On comprend qu'il faut trouver un **compromis** entre un modèle qui est très général (on dit qu'il est en situation de sous-apprentissage ou *underfitting*) et un modèle trop spécifique (sur-apprentissage ou *overfitting*).

Compromis biais-variance (1)

Trouver un compromis entre le biais et la variance du modèle :

- Le **biais** estime l' (in)capacité du modèle à capturer les véritables relations dans les données, en lien avec sa complexité / capacité / flexibilité.
- La **variance** estime l'écart des paramètres en fonction des données d'apprentissage.

F est la famille de fonctions qu'on chercher à approcher.

H est l'ensemble des hypothèses modélisées par notre famille de modèles.

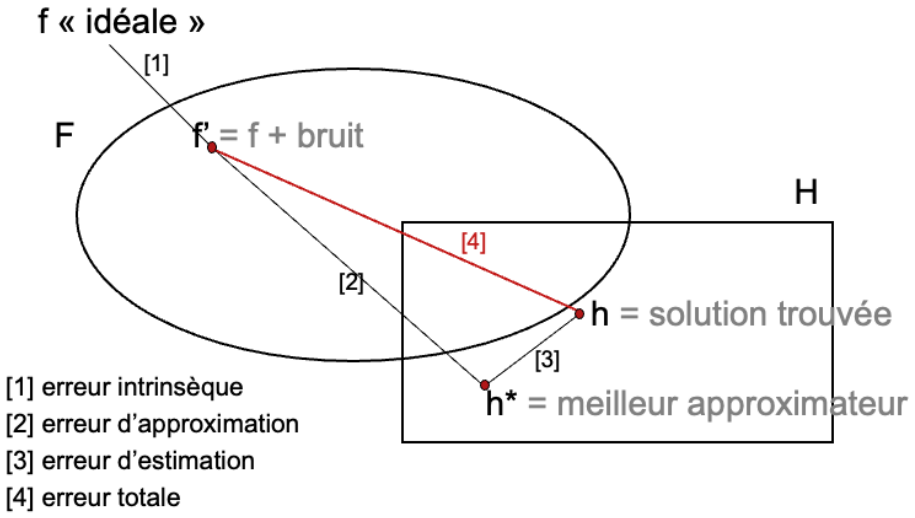

Compromis biais-variance (2)

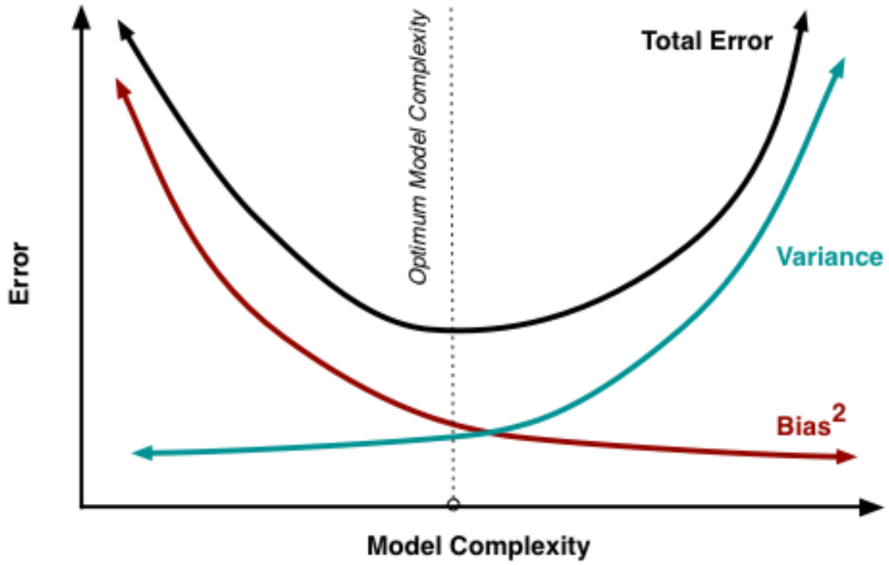

Classification automatique

Objectif : apprendre une fonction f qui attribue une classe à tout objet de l'espace de description

$$\begin{aligned} f : X &\longrightarrow C \\ x &\longmapsto c \in \{c_1, c_2 \dots c_k\} \end{aligned}$$

Classification automatique

Objectif : apprendre une fonction f qui attribue une classe à tout objet de l'espace de description

$$\begin{aligned} f : X &\longrightarrow C \\ x &\longmapsto c \in \{c_1, c_2 \ldots c_k\} \end{aligned}$$

De nombreux raffinements possibles : classes organisées en une hiérarchie, possibilité d'attribuer plusieurs classes (ou labels) à un même object (i.e. classification multi-labels), etc.

Comparaison de méthodes (1/3)

Comment comparer différentes méthodes de classification supervisée ?

Le premier critère est celui de l'**erreur de classification**. Attention à ne pas confondre :

- erreur apparente : comparer des méthodes en terme de taux de bon classement *sur l'échantillon d'apprentissage* ayant servi à estimer les paramètres favorisera toujours les méthodes les plus complexes

Comparaison de méthodes (1/3)

Comment comparer différentes méthodes de classification supervisée ?

Le premier critère est celui de l'**erreur de classification**. Attention à ne pas confondre :

- erreur apparente : comparer des méthodes en terme de taux de bon classement *sur l'échantillon d'apprentissage* ayant servi à estimer les paramètres favorisera toujours les méthodes les plus complexes
- erreur en généralisation : estimer la réussite du modèle sur un *échantillon de test* n'ayant pas servi à estimer les paramètres

Comparaison de méthodes (1/3)

Comment comparer différentes méthodes de classification supervisée ?

Le premier critère est celui de l'**erreur de classification**. Attention à ne pas confondre :

- erreur apparente : comparer des méthodes en terme de taux de bon classement *sur l'échantillon d'apprentissage* ayant servi à estimer les paramètres favorisera toujours les méthodes les plus complexes
- erreur en généralisation : estimer la réussite du modèle sur un *échantillon de test* n'ayant pas servi à estimer les paramètres

On peut même utiliser un *ensemble de validation* totalement indépendant des données utilisées pour entraîner afin de sélectionner les meilleurs modèles.

Comparaison de méthodes (1/3)

Comment comparer différentes méthodes de classification supervisée ?

Le premier critère est celui de l'**erreur de classification**. Attention à ne pas confondre :

- erreur apparente : comparer des méthodes en terme de taux de bon classement *sur l'échantillon d'apprentissage* ayant servi à estimer les paramètres favorisera toujours les méthodes les plus complexes
- erreur en généralisation : estimer la réussite du modèle sur un *échantillon de test* n'ayant pas servi à estimer les paramètres

On peut même utiliser un *ensemble de validation* totalement indépendant des données utilisées pour entraîner afin de sélectionner les meilleurs modèles.

Au-delà de l'erreur de classification, de nombreux **autres critères** peuvent être pertinents suivant le contexte : rapidité d'exécution, coût de l'inférence (par ex., coût environnemental), interprétabilité de la réponse du système, etc.

Comparaison de méthodes (2/3)

Comment estimer l'erreur de classification ?

On utilisera le plus souvent :

- un **échantillon test** : le taux de bon classement sera évalué sur un *échantillon test* n'ayant pas servi à estimer les règles de classement (découpage éch. existant souvent en 2/3 apprentissage 1/3 test)
- la **validation croisée** (cross validation - CV) *K-fold* où l'échantillon d'apprentissage est découpé en K partie, chaque partie servant tour à tour d'échantillon test
- la **validation croisée** *Leave One Out* = CV avec n folds

$$CV = \frac{1}{n} \sum_{i=1}^{n} \mathbb{1}_{\hat{z}_{(i)} = z_i}$$

  où $\hat{z}_{(i)}$ est la prédiction de la classe du $i$ème individu obtenu sans utiliser cet individu pour estimer les paramètres du modèle
- un **critère de choix de modèles** (comme BIC avec les approches probabilistes)

Comparaison de méthodes (3/3)

- **Aire sous la courbe ROC** (AUC) dans le cas de $K = 2$ classes, évaluée sur éch. test ou par CV (ici avec sensibilité vs. 1-spécificité)

		prédit		total
		$Z = 0$	$Z = 1$	
réel	$Z = 0$	VN	FP	N
	$Z = 1$	FN	VP	P
total		$\hat{N}$	$\hat{P}$	n

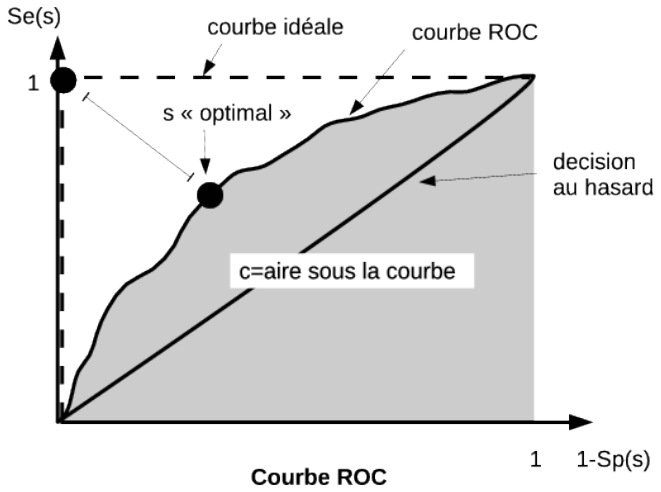

- *positif* : relatif à une modalité de référence ($Z = 1$, *malade*, *achat*...)
- s : seuil tel que $\widehat{Z} = 1$ si $p(\widehat{Z} = 1) \geq s$
- $Se(s) = \frac{VP}{VP+FN}$: sensibilité (taux de vrais positifs)
- $1 - Sp(s) = 1 - \frac{VN}{VN+FP}$: 1-spécificité (taux de faux positifs)

Exemple courbe ROC

Individu	Score (+)	Classe
1	1	+
2	0,95	+
3	0,93	+
4	0,85	-
5	0,8	+
6	0,75	-
7	0,7	-
8	0,65	+
9	0,6	-
10	0,55	-
11	0,5	-
12	0,5	+
13	0,5	-
14	0,35	-
15	0,3	-
16	0,25	-
17	0,2	-
18	0,15	-
19	0,15	-
20	0,05	-

Plan

Préambule
- Méthode scientifique
- Panorama des méthodes

Méthodologie
- Préparation
- Exploration
- Classification automatique
- Recherche d'information

Recherche d'information

- Historiquement, c'est une tâche qui a été beaucoup mobilisée lors du développement des moteurs de recherche suite à l'essor d'Internet
- Elle est souvent modélisée par une fonction qui, à partir d'une requête q et d'un ensemble d'objets D :
  - retourne l'ensemble des documents pertinents (*filtering*):

$$f_{filter} : q \longmapsto D_P \subset D$$

  - retourne une liste triée composée des objets pertinents (*ranking*) :

$$f_{rank} : q \longmapsto D_r = (d_{p1}, d_{p2} ... d_{p_N})$$

    tel que :
    - D_r est une séquence correspondant à une permutation des objets de D,
    - Si $i < j$ alors d_{pi} est au moins aussi pertinent que d_{pj} pour la requête q.

    Il suffit souvent de définir une fonction de *scoring* s qui attribue à chaque objet un score de pertinence.

Evaluation des solutions de RI

- La tâche de filtrage revient à résoudre un problème de classification supervisé binaire des objets : sont-ils pertinents ou non ?
- Dans ce cas, on peut recourir aux métriques vues précédemment.
- La solution employée utilisant souvent une méthode de *scoring*, on préfèrera employer les mesures de précision et de rappel :
  - La **précision** est la taux de vrais positifs : combien des objets retournés sont pertinents pour la requête ? Precision $= \frac{VP}{VP+FP}$
  - Le **rappel** (*recall* est le taux d'objets positifs retournés sur le nombre total d'objets positifs : Recall $= \frac{VP}{VP+FN}$
    On remarque que le rappel est synonyme à la mesure de sensibilité vue précédemment.
- Il est aussi possible d'utiliser une mesure moyenne appelée la **F-Mesure** (ou F-Score) : $\frac{2.precision.recall}{precision+recall}$

Utiliser des critères complémentaires

Aujourd'hui, on évalue souvent une solution à l'aide de nombreux critères complémentaires.

FairGPTQ (Proskurina et al., 2025)

Mthd.	Wiki↓	ArcE↑	Cloze↑	HSwag↑	PiQA↑	Cooc↓	CP↓	SS↓
Mistral-7B								
FP16	5.50	79.55	78.29	60.93	80.25	84.33	65.95	64.01
GPTQ-C4	5.66	78.87	77.83	60.04	79.60	76.64	66.61	63.88
GPTQ-SS	5.74	78.75	78.16	59.60	80.14	82.34	65.77	63.79
Fair-GPTQ$_{ALL}$	6.76	73.95	74.65	55.43	76.66	88.03	63.92	62.60
Fair-GPTQ$_{U}$	10.24	71.97	76.44	55.72	77.04	90.03	63.98	62.78
Fair-GPTQ$_{L}$	7.33	72.94	62.87	47.11	74.05	71.42	63.09	62.66
Fair-GPTQ$_{UL}$	8.24	69.23	73.33	54.28	75.52	61.25	63.92	63.46
OPT-6.7B								
FP16	10.24	65.57	73.73	50.51	76.28	74.93	67.98	66.97
GPTQ-C4	10.39	64.65	72.53	50.07	75.84	77.49	67.38	66.89
GPTQ-SS	10.83	64.94	72.67	49.76	75.90	74.36	67.74	66.88
Fair-GPTQ$_{ALL}$	13.21	62.88	69.89	46.39	73.23	65.53	67.26	66.92
Fair-GPTQ$_{U}$	11.47	63.80	73.00	49.79	75.79	71.51	67.50	66.99
Fair-GPTQ$_{L}$	13.26	63.76	71.81	47.00	73.83	73.79	63.51	64.35
Fair-GPTQ$_{UL}$	13.42	61.70	72.73	49.04	73.72	69.23	65.18	66.23

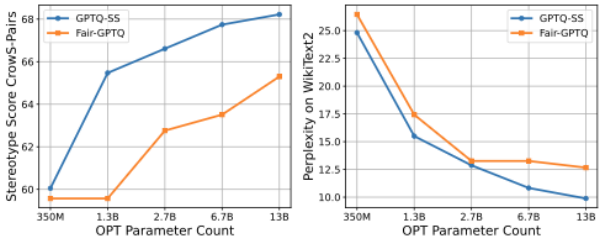

Model	GPTQ-SS	Fair-GPTQ
OPT-6.7B	7.98m	10.40m
OPT-13B	16.69m	17.10m
Mistral-7B	8.07m	10.59m

MDA-QA (Wang et al., 2025)

Method	Recall@10	Recall@20	Recall@50	EM@10	EM@20	EM@50
Chunk						
BM25	0.35 $\pm$ 0.34	0.42 $\pm$ 0.36	0.51 $\pm$ 0.37	0.12	0.19	0.28
Colbert	0.44 $\pm$ 0.32	0.52 $\pm$ 0.33	0.62 $\pm$ 0.33	0.16	0.25	0.36
BGE	0.49 $\pm$ 0.34	0.57 $\pm$ 0.35	0.66 $\pm$ 0.35	0.22	0.33	0.46
MPNET	0.41 $\pm$ 0.35	0.50 $\pm$ 0.37	0.60 $\pm$ 0.37	0.18	0.27	0.39
Doc						
BM25	0.44 $\pm$ 0.36	0.51 $\pm$ 0.37	0.60 $\pm$ 0.37	0.21	0.28	0.37
BGE	0.51 $\pm$ 0.36	0.58 $\pm$ 0.36	0.68 $\pm$ 0.35	0.27	0.36	0.48
MPNET	0.45 $\pm$ 0.37	0.54 $\pm$ 0.37	0.64 $\pm$ 0.37	0.24	0.32	0.45
BGE-neighbor	0.55 $\pm$ 0.40	0.63 $\pm$ 0.39	0.73 $\pm$ 0.36	0.37	0.46	0.57
MPNET-neighbor	0.48 $\pm$ 0.40	0.57 $\pm$ 0.40	0.68 $\pm$ 0.38	0.31	0.40	0.53

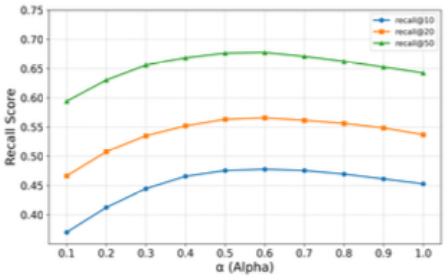

Method	M	R-L	C	B-F1
GPT-4o	0.16	0.19	0.54	0.18
w/ BGE	0.23	0.19	0.54	0.17
w/ BGE-neighbor	0.24	0.20	0.50	0.20

Quelques références

- Brochier R., A. Guille, J. Velcin (2019), Global Vectors for Node Representations, The Web Conference (WWW).
- Huang H., Velcin J., Kessaci Y. (2025), Towards Multi-Document Question Answering in Scientific Literature: Pipeline, Dataset, and Evaluation. EMNLP 2025, findings.
- Poux-Médard G., J. Velcin, S. Loudcher (2022), Serialized Interacting Mixed Membership Stochastic Block Model, ICDM.
- Proskurina I., Metzler G., Velcin J. (2025), Fair-GPTQ: Bias-Aware Quantization for Large Language Models, under review at AAAI.